

A Bőrtípus-Osztályozó Konvolúciós Hálózat (EfficientNetB3) Működése


Ez a dokumentum részletesen bemutatja a **Transfer Learning** alapú képosztályozó modell teljes életciklusát, az adatok előkészítésétől a többlépcsős finomhangolási folyamatig. A fő cél a bőrtípusok (**normál**, **száraz**, **zsíros**) pontos azonosítása képek alapján.

A Teljes Képzési Folyamat

A modell képzése progresszív finomhangolás mentén történik, kihasználva a TensorFlow és az EfficientNetB3 előnyeit.

- Adatok Előkészítése:** A tréning és validációs adatok beolvasása az adatgenerátorok segítségével történik.
A **tréning adatok** esetében augmentációt alkalmazunk (rotáció, zoom, eltolás stb.), hogy növeljük a modell robusztusságát és csökkentjük a túltanulás kockázatát.
- Modell Inicializálása (EfficientNetB3):** A bázismodell az EfficientNetB3, amely már rendelkezik az ImageNet adathalmazán megtanult, általános képi jellemzőkkel.
A modellre egy új, 3-osztályos kimenetet adunk.
- Többlépcsős Képzés:** A képzés három fázisra bomlik, minden fázisban csökkenő tanulási rátával, és fokozatosan több réteget "olvasztunk ki" (teszünk taníthatóvá) a bázismodellből. Ezzel biztosítjuk, hogy az értékes, ImageNet-ről örökölt súlyok ne sérüljenek az új, kisebb adathalmazon történő hirtelen, nagy lépésekkel való módosításkor.
- Optimalizáció és Védelem:** A képzés stabilitásáért az L2 regularizáció, a Dropout és a Batch Normalization rétegek felelnek, amelyek minimalizálják a túltanulást. Az automatikus képzésvezérléshez olyan visszahívásokat használunk, mint az EarlyStopping és a ReduceLROnPlateau, amelyek leállítják a felesleges képzést és optimalizálják a tanulási rátát.
- Végző Kimenet (Output):** A modell elmenti a legjobb teljesítményt nyújtó súlyokat (`val_accuracy`) alapján egyetlen `.keras` fájlba.

Funkciók:



A konvolúciós neurális hálózat (CNN) képzése összetett folyamat, amely több, egymásra épülő lépésből áll. A modell sikerességét a bemeneti adatok minősége, a hálózat architektúrája és az alkalmazott optimalizálási technikák összhangja határozza meg.

1. Adatok Előkészítése és Augmentáció

A modell nem nyers adatokkal, hanem előkészített bemenetekkel dolgozik.

Ennek célja: garantálni a modell számára a megfelelő felbontást és formátumot, valamint mesterségesen diverzifikálni a rendelkezésre álló adathalmazt.

1.1. Adatforrások és Címkézés

A rendszer kizárólag a **'oily' (zsíros)**, **'dry' (száraz)** és **'normal' (normál)** kategóriákra fókuszál.

A Keras keretrendszer az adatok elérési útból (`data/train` és `data/valid`) automatikusan elvégzi a címkézést (labeling): a képeket egyszerűen az alapján rendeli hozzá a megfelelő osztályhoz, hogy melyik alkönyvtárban találhatók.

1.2. Az ImageDataGenerator és az Augmentáció

Mivel a gépi tanulásban a minőségi adatok kulcsfontosságúak, a modell általánosítási képességének fokozása érdekében augmentációt alkalmazunk.

A **train_datagen** a meglévő képekből véletlenszerű transzformációk (pl. forgatás (90 fokig), szélesség- és magasságeltolás, zoomolás, fényerő-változtatás, valamint horizontális és vertikális tükrözés) révén gyakorlatilag végtelen számú új tréningmintát hoz létre.

Ez a technika a túlfitting megelőzéséhez kell.

A validációs adatok esetében viszont csak az előfeldolgozást (`preprocess_input`) alkalmazzuk, mert a modell teljesítményét valós, nem manipulált adatokon kell mérni.

1.3. Kötegelés

A képzési folyamat nem egyetlen képet dolgoz fel egyszerre, hanem 16 képből álló köteget (`BATCH_SIZE=16`)**.

2. Osztálysúlyok Számítása: A Kiegyensúlyozott Képzés

A valós adathalmazok szinte soha nem tökéletesen kiegyensúlyozottak. Például a 'normál' bőrtípusból több kép állhat rendelkezésre, mint a 'száraz' vagy 'zsíros' kategóriából. Ezt nevezzük **osztály-kiegyensúlyozatlanságnak**.

A Súlyozott Veszteségfüggvény

Ennek kezelésére a `class_weight='balanced'` paramétert használjuk. Ez a mechanizmus a ritkább osztályokhoz automatikusan nagyobb súlyt rendel. Amikor a modell hibázik egy ritka osztályú mintán, a veszteségfüggvény (**loss function**) nagyobb büntetést ad, mint amikor a gyakoribb osztályban hibázik. Ez arra kényszeríti a modellt, hogy jobban odafigyeljen a gyengén reprezentált osztályokra, elkerülve ezzel az adatok torzító hatását.

3. Modell Architektúra és Regularizáció

A modell az **EfficientNetB3** bázishálózaton alapul, amelyre egy egyedi osztályozó modult építünk.

3.1. A Bázismodell és a Transfer Learning

Az **EfficientNetB3** egy rendkívül hatékony konvolúciós hálózat. Az átviteli tanulás (Transfer Learning) elve alapján a modellt ImageNet súlyokkal töltjük be. Ezek a súlyok már általános tudást tartalmaznak a vonalakról, élekről és textúrákról. Kezdetben a bázismodellt fagyaszthatjuk (`trainable=False`), hogy megőrizzük ezt az értékes, előtanult tudást.

3.2. Osztályozó Fej

A bázismodell kimenetére új, sűrű (Dense) rétegeket adunk, amelyek elvégzik a specifikus bőrtípus-osztályozást:

- **GlobalAveragePooling2D:** Ez a réteg a sokdimenziós jellemző térképet egyetlen vektorra redukálja, ami jelentősen csökkenti a számítási terhet és a paraméterek számát.
- **BatchNormalization:** Minden réteg után normalizálja az aktivációkat. Ez stabilizálja a képzést és lehetővé teszi a nagyobb tanulási ráták használatát anélkül, hogy a hálózat divergálna.
- **Regularizáció (Dropout és L2):**

- **Dropout:** A képzés során véletlenszerűen kikapcsolja a neuronok egy részét (0.3 és 0.5 arányban). Ez arra kényszeríti a hálózatot, hogy ne egy-egy neuronra támaszkodjon, ezáltal növelve a robusztusságot és megelőzve a túltanulást.
- **L2 Regularization:** Ez a technika bünteti a túl nagy súlyokat a hálózatban. Az L2 norma $\$(0.001)\$$ hozzáadása a veszteségfüggvényhez segít megtartani a súlyokat alacsonyan, ami egy egyszerűbb és jobban általánosítható modellt eredményez.
- **Kimenet:** Az utolsó réteg 3 neuronnal és **softmax** aktivációval rendelkezik, amely az egyes kategóriákhoz tartozó valószínűségi eloszlást adja.

4. Visszahívások: Automatikus Képzésvezérlés

A visszahívások (Callbacks) olyan automatizált mechanizmusok, amelyek a képzés alatt figyelik a modell teljesítményét, és beavatkoznak, ha a feltételek megkívánják.

- **EarlyStopping:** A legfontosabb védelmi vonal a túltanulás ellen. Ha a validációs pontosság (**val_accuracy**) 12 epochon keresztül nem mutat javulást, a képzés leáll. A **restore_best_weights=True** beállítás biztosítja, hogy a leállításkor a modell a legjobb, valaha elért súlyokkal folytassa.
- **ReduceLROnPlateau:** Ha a validációs veszteség (**val_loss**) 4 epochon keresztül nem csökken, a tanulási ráta felére csökken. Ezzel a stratégiai lépéssel a modell el tud mozdulni a lokális minimumokról, és finomabban keresheti a globális optimumot.
- **ModelCheckpoint:** Ez a funkció folyamatosan figyeli a **val_accuracy** alakulását. Csak akkor menti el a modellt a lemezre, ha egy adott epochban a pontosság meghaladja az eddigi legjobb értéket. Ezzel garantáltan csak a legjobb modellváltozat kerül elmentésre.

5. Képzés Fázisai: Progresszív Finomhangolás:

Fázis 1: Jellemzők Kivonása, Fagyasztott Bázismodell.

Csak az új osztályozó rétegeket képezzük be. A magasabb tanulási ráta (10–3) gyorsan beállítja a kimeneti rétegeket az új feladathoz.

Fázis 2: Részleges Finomhangolás, "A bázismodell utolsó 100 rétegét kiolvasztjuk. Ezzel megengedjük a modellnek, hogy a kimenethez közelebbi, specifikus jellemzőket kinyerő rétegeket finoman adaptálja. A tanulási ráta tizedére csökken 10^{-4} , hogy elkerüljük az előtanult tudás hirtelen felülírását."

Fázis 3: Mély Finomhangolás, "A teljes bázismodell kiolvasztva. Minden súly tanítható. A tanulási ráta még egyszer tizedére csökken 10^{-5} , ami rendkívül lassú, finom konvergenciát tesz lehetővé, ami kritikus a legmagasabb validációs pontosság eléréséhez."

Szótár:

Fogalom	Angol Megfelelő	Működés és Indoklás
Konvolúciós Neurális Hálózat	<i>Convolutional Neural Network (CNN)</i>	Különösen képi adatok feldolgozására tervezett mélytanulási architektúra. A konvolúciós rétegek automatikusan tanulják meg a képek hierarchikus jellemzőit (élek, textúrák, formák), ahelyett, hogy mi kódolnánk be őket.
EfficientNetB3	<i>EfficientNetB3</i>	Egy modern és nagy teljesítményű, előtanított CNN modellecsalád tagja (a B3-as változat), amely kiemelkedő pontosságot és viszonylag alacsony számítási igényt kombinál. Ez a modell szolgál a Transfer Learning alapjául.
Transfer Learning	<i>Transfer Learning</i>	Átviteli tanulás. A technika lényege, hogy egy nagy adathalmazon (pl. ImageNet) betanított modell tudását vesszük át (súlyait), és azt finomhangoljuk egy új, de rokon feladatra (esetünkben bőrtípus-osztályozás). Ezzel rengeteg időt és számítási erőforrást takarítunk meg.
ImageNet	<i>ImageNet</i>	Egy hatalmas, több mint 14 millió címkézett képből álló adathalmaz. A legtöbb nagy CNN modellt (mint az EfficientNet) ezen az adatkészleten tanítják be, hogy általános vizuális jellemzőket sajátítsanak el.
Túltanulás	<i>Overfitting</i>	Akkor következik be, ha a modell túl jól teljesít a tréning adatokon, de rosszul általánosít új, nem látott adatokon. A modell lényegében "bepamlagolja" a tréning adatokat, ahelyett, hogy megtanulná az alapvető mintázatokat.
Batch	<i>Batch (Köteg)</i>	A tréning adatok azon részhalmaza, amelyet a modell egyszerre, egy lépésben feldolgoz, mielőtt a súlyokat frissítené. A kódunkban ez az érték 16 képet jelent.
Epoch	<i>Epoch</i>	A képzési folyamat egy teljes ciklusa, amely során a modell az összes tréning adaton (az összes batchen) egyszer áthalad. A képzés több epochon keresztül zajlik.

Fogalom	Angol Megfelelő	Működés és Indoklás
Loss Function	<i>Loss Function</i>	Veszteségfüggvény (esetünkben <i>categorical_crossentropy</i>). Számolja a különbséget a modell által előre jelzett érték és a valódi címke között. A képzés célja ennek az értéknek a minimalizálása.
TensorFlow	<i>TensorFlow</i>	Egy nyílt forráskódú szoftverkönyvtár, amelyet a Google fejlesztett ki numerikus számításokhoz és nagyméretű gépi tanulási alkalmazások létrehozásához.
L2 Regularizáció	<i>L2 Regularization</i>	Egy technika a túltanulás megelőzésére. Hozzáad egy büntetést a veszteségfüggvényhez, amely a hálózat súlyainak négyzetével arányos. Ez arra ösztönzi a modellt, hogy kisebb, kevésbé extrém súlyokat használjon, ami egy egyszerűbb és általánosíthatóbb modellt eredményez.
Dropout	<i>Dropout</i>	Szintén túltanulást gátló technika. A képzés minden lépésében véletlenszerűen kikapcsolja (nullára állítja) a réteg neuronjainak egy előre meghatározott részét (pl. 30% vagy 50%). Ez arra kényszeríti a hálózatot, hogy ne egyetlen neuronra támaszkodjon, hanem robusztusabb reprezentációkat tanuljon.
Batch Normalization	<i>Batch Normalization</i>	A rétegek bemeneti adatait normalizálja az aktuális batch átlaga és szórása alapján. Ez drámaian felgyorsítja és stabilizálja a képzést, különösen a mély hálózatokban, lehetővé téve a nagyobb tanulási ráták használatát.
GlobalAveragePooling2D	<i>Global Average Pooling 2D</i>	Egy réteg, amely a konvolúciós rétegek kimenetét (jellemző térképeket) összenyomja a felbontás átlagolásával, így minden jellemző térképből egyetlen számot állít elő. Ez csökkenti a paraméterek számát és segít az áttérésben a konvolúciós rétegekről a sűrű (Dense) osztályozó rétegekre.